

自然语言处理技术在推荐系统中的应用

1 问题引入

推荐系统（Recommend System, RS）旨在通过分析用户的历史行为偏好自动提供个性化的内容推荐。以视频推荐任务为例，推荐系统将根据视频内容与用户浏览历史为用户推送视频，从而帮助用户拓宽视野、发现符合其兴趣的新内容。在互联网技术不断发展，电商、社交与流媒体平台持续产生巨量信息的当下，推荐系统凭借其在缓解信息过载、丰富用户体验上的显著优势得到了广泛应用，具有重要的研究意义。

1.1 传统推荐系统及其困境

传统的推荐系统基于矩阵分解技术或聚类算法实现：前者将“用户—产品”矩阵分解为多个低秩矩阵的乘积以捕捉用户和产品的隐含特征，能有效处理稀疏数据，但计算开销大、难以处理超大规模数据；后者基于 K-Means、K 近邻（K-Nearest Neighbor, KNN）等经典聚类算法对用户、产品分别进行聚类，分别基于用户簇、产品簇实现对相似用户和相似产品的挖掘，进而生成推荐建议。但该类方法无法应对冷启动场景、且不支持并行计算，难以满足大数据时代的需求。

随着深度学习技术的发展，各类深度神经网络已被广泛应用于用户和产品的表征学习与文本侧信息挖掘，推动了推荐系统的发展进程。由于其对序列数据的优秀处理能力，循环神经网络（Recurrent Neural Networks, RNNs）被广泛的用于捕捉“用户—产品”交互序列中的多粒度依赖关系。将用户行为建模为图结构数据，图神经网络（Graph Neural Networks, GNNs）与消息传递策略也被广泛应用于用户和产品的表征学习任务中。为对齐用户和产品侧知识，Deep CoNN 通过两个孪生神经网络编码用户对产品的评论文本，从而实现更准确的评分预测^[1]。NARRE 引入了注意力机制，同时生成推荐评分与基于评论的解释文本^[2]。相比于传统方法，基于深度学习的推荐系统能融合类型各异的多源异

构数据，自动实现对隐藏特征的学习及对用户序列行为的建模，进而更准确地区分用户偏好、提供推荐建议。

然而，基于深度学习的推荐系统仍存在一些内在局限性。受限于模型和数据集规模，此类推荐系统通常无法充分捕捉物品文字描述中隐含的知识，导致在部分推荐场景中表现欠佳。其次，这些基于在线收集用户行为数据进行隐式建模的推荐方式在可解释性上存在显著缺陷。此外，大多数现有的推荐系统都是基于特定领域的离散特征构建的^[3]，缺乏开放域下的世界知识，在针对未知物品推荐任务中表现出较差的泛化性^[4,5]。

1.2 大语言模型时代下的推荐系统

随着近年来自然语言处理技术的进步，拥有数十亿参数的大型语言模型（Large Language Models, LLMs）在计算机视觉^[6]和分子发现^[7]等多个研究领域产生了重大影响。得益于其对开放世界知识的强大记忆能力和推理能力以及对人类社会和文化的理解，LLMs 能够将自然语言作为通用信息载体，整合、利用不同形式、不同领域的知识，为解决数据挖掘领域的许多挑战性问题提供通用的解决方案。

近期，研究者们开始探索利用 LLMs 所具备的通用知识解决传统推荐系统的固有缺陷的途径。例如：Chat-Rec^[8]通过 ChatGPT 与用户间的对话互动，进一步优化传统 RS 生成的推荐电影候选集，以增强推荐的准确性和可解释性。Zhang 等人^[9]设计了基于大语言模型 T5 的推荐系统，让用户通过自然语言输入其偏好，并取得了比基于“用户—产品”交互更优的推荐性能。

本文将在第二节中讨论 LLMs 与 RS 结合的两范式，在第三节中陈述个人对于 LLMs 赋能 RS 中存在的挑战的理解、并对未来的研究方向进行展望。

2 方法总结

2.1 基于 LLMs 的深度表征学习

LLMs 通常在以下两类推荐系统模型中被应用于表征学习模块：

2.1.1 基于 ID 的推荐系统

这类推荐系统通过为用户和产品赋予唯一 ID 以进行标识，基于深度学习方法或 LLMs 学习 ID 对应的嵌入向量，并最终以此为依据产生最终的推荐结果。

P5^[10]是此类方法中的一个早期范式，该方法将用户和物品映射为 ID，从而把不同格式（如“用户—产品”交互、用户画像、产品文本描述、用户评论等）的推荐数据统一转化为自然语言序列。后续的方法大多在 P5 的基础上继续改进映射方式，以生成更高质量的自然语言序列。例如，Hua 等人^[11]将 P5 的随机分配 ID 改进为语义 ID，有效提高了表征的信息含量。

2.1.2 基于文本信息的推荐系统

然而，基于 ID 的推荐系统具有严重的内在局限性——用户和产品 ID 本质上是离散的，无法提供足够的语义信息以挖掘用户和物品的表征。这导致“用户—产品”间的相关性计算变得相当棘手。

摆脱这一困境，研究者们提出了基于文本信息的推荐系统。该类方法将语言模型（如 BERT）作为编码器，将用户和产品的文本描述信息映射到语义空间，从而更高效的对相似的用户和产品进行分组，并以更细粒度的方式确定它们的差异。Unisec^[12]就是一种基于产品的文本描述信息学习可迁移表征的方案：该方法引入了一个轻量级编码器，并使用参数化白化和专家混合（Mixture of Experts, MoE）增强适配器。该研究同时也证明了基于文本的协同过滤推荐系统相比于基于 ID 的方案性能更优。

但是，仅依靠 LLMs 编码产品的文本信息可能会导致过分强调文本特征。为解决这一问题，VQ-Rec^[13]提出通过向量标识产品的方法，通过将产品文本信息映射为离散索引的向量，并使用这些向量从嵌入表中检索产品表征。此外，Fan 等人^[14]提出了一种基于产品的零样本推荐方法，通过向 LLMs 引入产品知识图谱以改进产品表征。

2.2 基于提示的下游任务适应

提示（Prompt）指代的是可以作为 LLMs 输入的文本模版。例如，我们可以通过提示模版“The relation between [A] and [B] is”让 LLMs 完成关系提取任务。基于提示的范式能够将不同的下游任务（如电影推荐、药品推荐等）统一为自然

语言生成任务，从而与 LLMs 在预训练期间的目标对齐^[15]。相比于需要大规模特定数据集的预训练范式与高参数更新成本的微调范式，基于提示的下游任务因冻结了 LLMs 参数显得更加轻量化。本节将介绍三种典型的手动提示设计方法：最近的研究积极探索了通过提示（Prompting）来促进 LLMs 在推荐任务中的表现，先进技术如上下文学习（ICL）和思维链（CoT）正越来越多地被研究用于手动设计各种推荐任务的提示。此外，提示微调作为提示的附加技术，通过向 LLMs 添加提示标记并基于任务特定的推荐数据集更新它们。最近，结合预训练和微调范式与提示的指令微调^[123]被探索，用于通过基于指令的提示来微调 LLMs 以处理多个推荐任务，从而增强 LLMs 在未见推荐任务上的零样本性能。图 6 比较了每种提示技术在推荐系统中对应的代表性方法，展示了 LLMs 的工作流程、输入格式和参数更新（即可调或冻结）。在本节中，我们将详细讨论提示、提示微调和指令微调技术，以提高 LLMs 在推荐任务中的性能。总而言之，表 3 按照上述三种技术对现有工作进行了分类，包括这些工作中涉及的具体推荐任务和 LLM 骨干。

2.2.1 传统提示设计

传统的提示设计方法主要可以被归纳为两类：（1）提示工程（Prompt Engineering）：该方法旨在模拟 LLMs 在预训练期间使用的语料，从而使语言模型将下游任务与未知目标统一为目标已知的自然语言生成任务。例如 Liu 等人^[16]使用“Write a short sentence to summarize”作为提示，将推荐系统中的产品评论摘要任务统一化为通用的文本摘要任务。（2）少样本提示（Few-shot Prompting）：该方法为 LLMs 提供了少量“输入—输出”示例来提示和引导预训练的语言模型为特定下游任务生成所需的输出。

然而，由于自然语言生成任务和下游推荐任务之间的巨大差距，大多数传统的提示方法仅在与语言生成任务相似特定任务中（如用户评论摘要^[16]和产品间关系标注^[17]）起效。

2.2.2 上下文学习

上下文学习（In-Context Learning, ICL）^[18]是与 GPT-3 同时提出的一种高级提示设计策略。ICL 提出了少样本和零样本两种设置方式，前者为 LLMs 同时提供示例与提示，而后者仅提供特定下游任务的自然语言描述。这种设计在推理阶

段通过上下文引导 LLMs 学习新的或未见过的下游任务，显著提高了 LLMs 在不同下游任务的适应能力。许多现有研究同时考虑了少样本 ICL 和零样本 ICL 设置，并比较两者在相同推荐任务下的性能。通常情况下，少样本 ICL 因提供了额外的上下文示例而取得比零样本 ICL 更优的表现。

ICL 策略在推荐系统中同样有两种不同的使用方式。一种较为直接的方法是教 LLMs 充当推荐者。例如，Liu 等人^[16]为不同的推荐任务（包括 top-K 推荐、评分预测和解释生成）提出了各异的任务描述，如用户评分历史将被作为评分预测任务的示例。[19]则提出了一种类似于角色扮演的提示设计方案（如“You are a book rating expert”）以防止 LLMs 拒绝完成推荐任务。另一种方法则通过 ICL 连接 LLMs 和传统推荐模型。例如，Chat-Rec^[8]通过 ICL 让 ChatGPT 学习接受传统推荐系统给出的候选项，加以优化后得到最终推荐结果。此外，Zhang^[20]设计了一个外部图推理工具的文本 API 调用模板，并通过 ICL 教会 ChatGPT 进行使用以访问由外部工具生成的推荐结果。

2.1.3 思维链

思维链（Chain-of-Thought, CoT）^[21]是最新的一种提示策略，该方法通过注释中间推理步骤帮助 LLMs 分解复杂决策过程，弥补了 ICL 在多步推理任务中存在的不足：例如在数学推导任务中，基于 ICL 生成的答案经常缺少若干中间推理步骤、导致推理逻辑断裂，进而导致一连串的推理错误。

考虑到为适应具有复杂推理的各种下游任务，Zhao 等人^[22]讨论了 ICL 与 CoT 的结合方式：通过插入诸如“Let’s think step by step”和“Therefore, the answer is”这的文本提示，零样本引导 LLMs 独立生成任务特定的推理步骤，而不提供任何任务相关的指导或示例；在少样本情形下，则为每个示例手动设计任务特定的推理步骤，将原始的“输入—输出”示例扩展为“输入—CoT—输出”格式。此外，CoT 还可以通过添加基于任务特定知识的可解释推理步骤描述来增强 ICL 示例中的任务描述。

3 个人对问题的理解

随着自然语言处理技术的飞速发展，LLMs + X 已经成为近期大热的研究范式。也正如第二节中所述，大预言模型为推荐系统的泛化性与准确性带来了显著提升，但自然语言处理技术与推荐系统的融合仍存在诸多挑战：

语言模型的幻觉现象仍待解决 “幻觉”是指语言模型生成听起来合理但实际上不正确或与输入数据无关的输出的现象。例如，假设你在寻找今天的新闻事件，但 LLMs 错误地推荐/生成了实际上不存在的新闻。而在推荐系统领域，这意味着系统向用户推荐了一个完全不存在的产品。为了解决这一问题，我们可以在 LLMs 的训练和推理阶段，使用事实知识图作为补充知识。此外，也可以在模型输出阶段对生成的内容进行审核，以确保其真实性。

推荐系统领域的垂域大预言模型仍存在空缺 垂域大模型是指针对特定领域（如法律、金融等）进行训练和优化的 LLMs。相比于通用 LLMs，垂域 LLM 赋能的推荐系统将能更专注于特定推荐领域的知识和技能，具有更高的领域专业性和实用性。然而，构建垂域大模型需要大量的领域特定数据，这为数据收集与标注带来了显著的挑战。

推荐过程与结果的可解释性仍存在欠缺 由于隐私和安全考虑，某些公司和组织选择不开源他们的大预言模型，这意味着这些用于推荐系统的 LLMs 将成为“黑盒子”，使用户难以理解推荐建议的产生机制。

参考文献

- [1] Zheng L, Noroozi V, Yu P S. Joint deep modeling of users and items using reviews for recommendation[C]//Proceedings of the tenth ACM international conference on web search and data mining. 2017: 425-434.
- [2] Chen C, Zhang M, Liu Y, et al. Neural attentional rating regression with review-level explanations[C]//Proceedings of the 2018 world wide web conference. 2018: 1583-1592.
- [3] Xi Y, Liu W, Lin J, et al. Towards open-world recommendation with knowledge augmentation from large language models[C]//Proceedings of the 18th ACM Conference on Recommender Systems. 2024: 12-22.

- [4] Harte J, Zorgdrager W, Louridas P, et al. Leveraging large language models for sequential recommendation[C]//Proceedings of the 17th ACM Conference on Recommender Systems. 2023: 1096-1102.
- [5] Liu Q, Chen N, Sakai T, et al. A first look at llm-powered generative news recommendation[J]. arXiv preprint arXiv:2305.06566, 2023.
- [6] Zhou L, Palangi H, Zhang L, et al. Unified vision-language pre-training for image captioning and vqa[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(07): 13041-13049.
- [7] Li J, Liu Y, Fan W, et al. Empowering molecule discovery for molecule-caption translation with large language models: A chatgpt perspective[J]. IEEE Transactions on Knowledge and Data Engineering, 2024.
- [8] Gao Y, Sheng T, Xiang Y, et al. Chat-rec: Towards interactive and explainable llms-augmented recommender system[J]. arXiv preprint arXiv:2303.14524, 2023.
- [9] Zhang J, Xie R, Hou Y, et al. Recommendation as instruction following: A large language model empowered recommendation approach[J]. arXiv preprint arXiv:2305.07001, 2023.
- [10] Geng S, Liu S, Fu Z, et al. Recommendation as language processing (rlp): A unified pretrain, personalized prompt & predict paradigm (p5)[C]//Proceedings of the 16th ACM Conference on Recommender Systems. 2022: 299-315.
- [11] Hua W, Xu S, Ge Y, et al. How to index item ids for recommendation foundation models[C]//Proceedings of the Annual International ACM SIGIR Conference on Research and Development in Information Retrieval in the Asia Pacific Region. 2023: 195-204.
- [12] Hou Y, Mu S, Zhao W X, et al. Towards universal sequence representation learning for recommender systems[C]//Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2022: 585-593.
- [13] Hou Y, He Z, McAuley J, et al. Learning vector-quantized item representation for transferable sequential recommenders[C]//Proceedings of the ACM Web Conference 2023. 2023: 1162-1171.
- [14] Fan Z, Liu Z, Heinecke S, et al. Zero-shot item-based recommendation via multi-task product knowledge graph pre-training[C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. 2023: 483-493.
- [15] Gao T, Fisch A, Chen D. Making pre-trained language models better few-shot learners[J]. arXiv preprint arXiv:2012.15723, 2020.
- [16] Liu J, Liu C, Zhou P, et al. Is chatgpt a good recommender? a preliminary study[J]. arXiv preprint arXiv:2304.10149, 2023.
- [17] Chen J, Ma L, Li X, et al. Knowledge graph completion models are few-shot learners: An empirical study of relation labeling in e-commerce with llms[J]. arXiv preprint arXiv:2305.09858, 2023.

- [18] Brown T B. Language models are few-shot learners[J]. arXiv preprint arXiv:2005.14165, 2020.
- [19] Zhiyuli A, Chen Y, Zhang X, et al. Bookgpt: A general framework for book recommendation empowered by large language model[J]. arXiv preprint arXiv:2305.15673, 2023.
- [20] Zhang J. Graph-toolformer: To empower llms with graph reasoning ability via prompt augmented by chatgpt[J]. arXiv preprint arXiv:2304.11116, 2023.
- [21] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.
- [22] Zhao W X, Zhou K, Li J, et al. A survey of large language models[J]. arXiv preprint arXiv:2303.18223, 2023.